Clasificador de gastos con IA

Escribís un gasto como lo anotarías en el celular y la app lo clasifica sola

Araceli Amherdt · Seminario de Actualización · IFTS N.º 18 · 2026

Un gasto, mil formas de escribirlo

“cargué la SUBE”	→	**transporte**
“el bondi”	→	**transporte**
“5 lucas a Juan por el asado”	→	**comida**
“birras con los pibes”	→	**ocio**
“el chino de la esquina”	→	**comida**

¿Por qué IA y no un if?

Una lista de palabras clave nunca termina: siempre aparece una frase que no preví.

El modelo interpreta el significado, sin reglas escritas a mano.

6 categorías: comida · transporte · servicios · salud · ocio · educación

mDeBERTa: acierta más y pesa menos

mDeBERTa

elegido

MoritzLaurer/mDeBERTa-v3-base-mnli-xnli

13/15	558 MB	20 s
aciertos	de pesos	de carga

0,3B parámetros

xlm-roberta-large

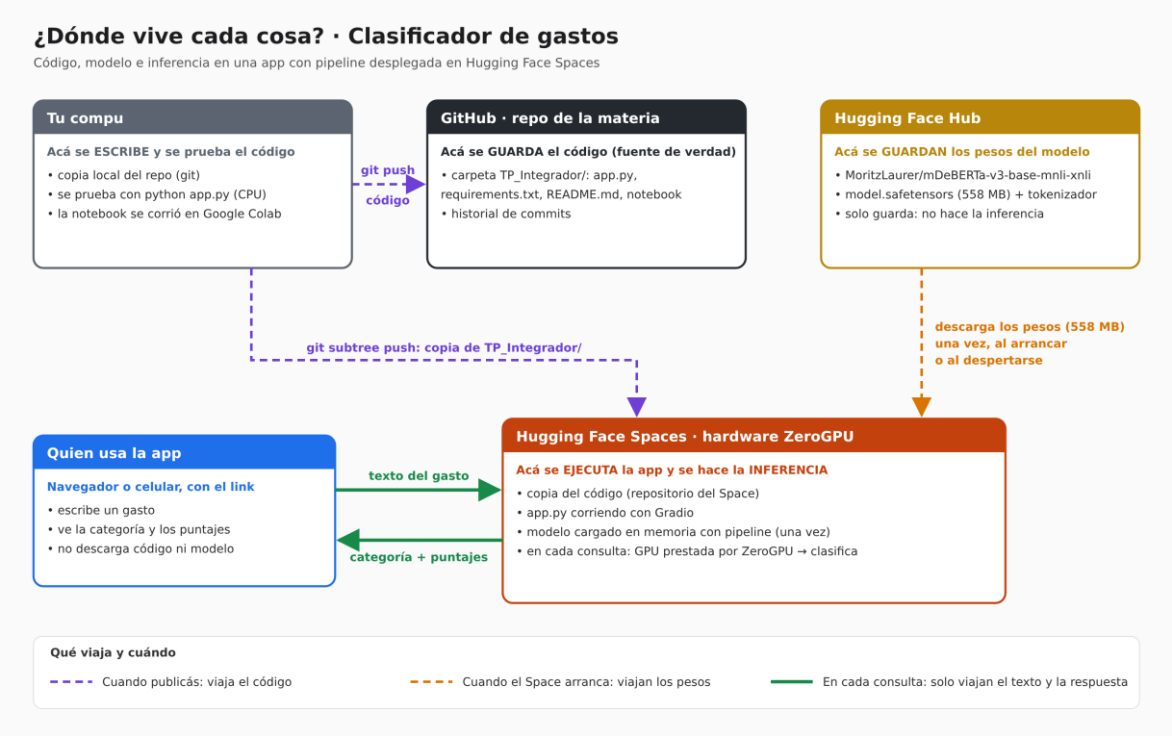
joeddav/xlm-roberta-large-xnli

6/15	2,24 GB	54 s
aciertos	de pesos	de carga

0,56B parámetros

Más grande no significó mejor: casi el doble de parámetros y menos de la mitad de aciertos.

Dónde vive cada cosa



Código
guardado en GitHub

Pesos
guardados en el Hugging Face Hub

Inferencia
en el Space, con la GPU de ZeroGPU

Deploy: Spaces con pipeline

ELEGIDO

Hugging Face Spaces (PaaS) + pipeline

- El modelo (558 MB) y torch entran sin administrar un servidor
- No gasta créditos por consulta
- Hardware ZeroGPU: CPU Basic dejó de ser gratis en julio de 2026

DESCARTADAS

InferenceClient
Sin créditos (error 402): la app estaría caída en la corrección

Serverless
Cargaría el modelo (20 s) en cada arranque en frío

Hosting compartido
No soporta torch ni un modelo en memoria

La app funcionando



huggingface.co/spaces/AraceliAmherdt/Clasificador_gastos

“birras con los pibes” → ocio, 87 %. Muestra las tres categorías más probables, así se ve cuándo el modelo duda.

El error que cambió el diseño

```
HfHubHTTPError:
402 Payment Required

You have no remaining credits.
Purchase pre-paid credits to continue
using Inference Providers.
```

Qué pasó

Al llamar al modelo con InferenceClient se agotaron los créditos gratuitos (menos de USD 0,10 por mes). Vuelven en noviembre.

Qué aprendí

Si la app depende de un servicio que no controlo, se cae aunque el código esté bien. Por eso pasé a pipeline.

Límites y próximo paso

1

1000 personas a la vez

Un solo servidor y GPU prestada por turnos: las consultas harían fila.

2

Cambios del plan gratuito

Ya pasó: CPU Basic dejó de ser gratis y tuve que adaptar la app.

3

Siempre elige una categoría

Reparte el 100 %, aunque lo escrito no sea un gasto.

PRÓXIMO PASO

Si la mejor categoría queda por debajo del 50 %, que la persona elija. Y guardar los gastos con montos y fechas.